LAVORO DI GRUPPO OUTLIERS & SPLITTING DATASET

March 12, 2024

1 OUTLIERS & SPLITTING DATASET

1.1 CREATO DA GRANIERI JOELE, TASSONE LEONARDO, RAPHAEL RODRIGO E RADISHA WARNAKULASURIYA

1.2 SPLITTING DATASET

1.2.1 Analisi e Preparazione dei Dati: Un Esempio con Altezze e Pesi

[1]:
```
import numpy as np
from sklearn.model_selection import train_test_split

# Creare dati casuali per altezze (variabile indipendente) e pesi (variabile␣
 ↪dipendente)
np.random.seed(0)
altezze = np.random.normal(160, 10, 100)
pesi = 0.5 * altezze + np.random.normal(0, 5, 100)

# Suddividere il dataset in training set (70%) e test set (30%)
X_train, X_test, y_train, y_test = train_test_split(altezze, pesi, test_size=0.
 ↪3, random_state=42)

# Stampare le dimensioni dei training set e test set
print("Dimensioni del Training Set (altezze e pesi):", X_train.shape, y_train.
 ↪shape)
print("Dimensioni del Test Set (altezze e pesi):", X_test.shape, y_test.shape)
```

```
Dimensioni del Training Set (altezze e pesi): (70,) (70,)
Dimensioni del Test Set (altezze e pesi): (30,) (30,)
```

Questo codice esegue le seguenti operazioni:

Genera dati casuali per altezze e pesi: Crea un set di dati di 100 punti, dove le altezze sono generate casualmente da una distribuzione normale con media 160 e deviazione standard 10. I pesi sono generati come il 50% delle altezze più un rumore casuale da una distribuzione normale con media 0 e deviazione standard 5.

Suddivide il dataset in training set e test set: Il dataset viene suddiviso in un training set (70% dei dati) e un test set (30% dei dati). Questo è fatto per avere un set di dati separato (test set) per valutare le prestazioni del modello che sarà addestrato sul training set.

Stampa le dimensioni dei training set e test set: Infine, il codice stampa le dimensioni dei training set e test set. Questo è utile per verificare che la suddivisione dei dati sia stata eseguita correttamente.

In sintesi, questo codice è un esempio di come si potrebbe preparare un set di dati per un problema di apprendimento supervisionato, come la regressione lineare, dove si cerca di prevedere il peso (variabile dipendente) in base all'altezza (variabile indipendente).

1.2.2 Analisi della correlazione tra le visite al sito web e l'importo delle vendite

[2]:
```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split

# Creazione di dati casuali per visite al sito web e importo delle vendite
np.random.seed(0)
visite_al_sito = np.random.randint(100, 1000, 1000)
importo_vendite = 50 + 0.2 * visite_al_sito + np.random.normal(0, 10, 1000)

# Suddivisione del dataset in training set (70%) e test set (30%)
X_train, X_test, y_train, y_test = train_test_split(visite_al_sito,␣
 ↪importo_vendite, test_size=0.3, random_state=42)

# Creazione di un grafico a dispersione
plt.figure(figsize=(10, 6))
plt.scatter(X_train, y_train, label='Training Set', color='blue', alpha=0.7)
plt.scatter(X_test, y_test, label='Test Set', color='orange', alpha=0.7)
plt.xlabel('Numero di Visite al Sito')
plt.ylabel('Importo delle Vendite')
plt.title('Relazione tra Visite al Sito e Importo delle Vendite')
plt.legend()
plt.grid(True)
plt.show()

# Stampare le dimensioni dei training set e test set
print("Dimensioni del Training Set (visite al sito e importo delle vendite):",␣
 ↪X_train.shape, y_train.shape)
print("Dimensioni del Test Set (visite al sito e importo delle vendite):",␣
 ↪X_test.shape, y_test.shape)
```

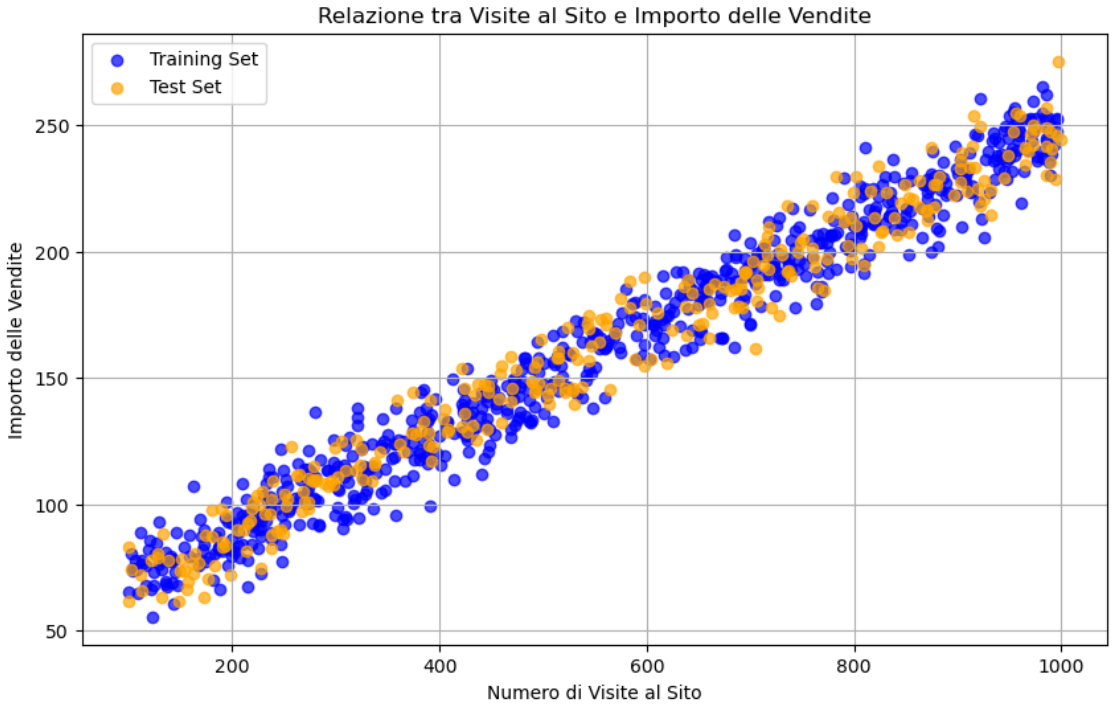


```
Dimensioni del Training Set (visite al sito e importo delle vendite): (700,)
(700,)
Dimensioni del Test Set (visite al sito e importo delle vendite): (300,) (300,)
```

> Questo script Python utilizza le librerie numpy, matplotlib e sklearn per creare un modello di regressione lineare semplice.

Prima di tutto, genera un set di dati casuali che rappresentano le visite al sito web e l'importo delle vendite. L'importo delle vendite è calcolato come una funzione lineare delle visite al sito web, più un po' di rumore casuale.

Successivamente, suddivide il set di dati in un training set (70% dei dati) e un test set (30% dei dati) utilizzando la funzione train_test_split di sklearn.

Poi, crea un grafico a dispersione dei dati. I punti blu rappresentano il training set e i punti arancioni rappresentano il test set. L'asse x rappresenta il numero di visite al sito, mentre l'asse y rappresenta l'importo delle vendite.

Infine, stampa le dimensioni del training set e del test set.

1.2.3 Analisi Statistica di un Campione Estratto da un Dataset: Un Esempio con Numeri Casuali

[3]:
```
import random
import numpy as np

dataset=[]
```

```python
# Creazione di un dataset di 1000 elementi (ad esempio, dati casuali)
for i in range(1000):
    dataset.append(random.randint(1, 100))

# Estrazione di un campione casuale semplice di 50 elementi dal dataset
campione_casuale = random.sample(dataset, 300)

# Calcolo della media e della deviazione standard del campione
media_campione = np.mean(campione_casuale)
deviazione_standard_campione = np.std(campione_casuale)

# Calcolo della media e della deviazione standard del dataset completo
media_dataset = np.mean(dataset)
deviazione_standard_dataset = np.std(dataset)

print(f"Media del campione casuale: {media_campione: .2f}")
print(f"Deviazione standard del campione casuale: {deviazione_standard_campione:
 ↪ .2f}")
print(f"Media del dataset completo: {media_dataset: .2f}")
print(f"Deviazione standard del dataset completo: {deviazione_standard_dataset:␣
 ↪.2f}")
```

```
Media del campione casuale:  50.14
Deviazione standard del campione casuale:  28.80
Media del dataset completo:  49.85
Deviazione standard del dataset completo:  29.23
```

Questo codice esegue le seguenti operazioni:

Crea un dataset di 1000 elementi: Genera un dataset di 1000 numeri interi casuali tra 1 e 100.

Estrae un campione casuale dal dataset: Estrae un campione casuale di 300 elementi dal dataset.

Calcola la media e la deviazione standard del campione: Calcola la media e la deviazione standard dei valori nel campione casuale.

Calcola la media e la deviazione standard del dataset completo: Calcola la media e la deviazione standard dei valori nel dataset completo.

Stampa i risultati: Stampa la media e la deviazione standard sia del campione casuale che del dataset completo.

In sintesi, questo codice è un esempio di come si potrebbe eseguire un'analisi statistica su un campione di dati estratto da un dataset più grande. Questo è un concetto comune in statistica, dove spesso si lavora con campioni di dati piuttosto che con l'intero dataset. Questo può essere utile quando il dataset completo è troppo grande per essere gestito efficacemente, o quando si desidera stimare le proprietà di una popolazione più grande basandosi su un campione di essa.

1.2.4 Generazione di un DataFrame con distribuzione personalizzata

[4]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split

# Impostare il seed per la riproducibilità
np.random.seed(42)
# Numero totale di elementi nel DataFrame
num_elementi = 1000
# Percentuale di "A"
percentuale_A = 0.7
# Generare la colonna con distribuzione desiderata
colonna = np.random.choice(['A', 'B'], size=num_elementi, p=[percentuale_A, 1 -␣
 ↪percentuale_A])

# Creare il DataFrame
df = pd.DataFrame({'ColonnaAB': colonna})
df
```

[4]:
```
    ColonnaAB
0           A
1           B
2           B
3           A
4           A
..        …
995         A
996         B
997         A
998         B
999         A

[1000 rows x 1 columns]
```

Questo codice Python crea un DataFrame pandas con una singola colonna chiamata 'ColonnaAB'. La colonna contiene 1000 elementi, ognuno dei quali è una stringa che può essere 'A' o 'B'.

La distribuzione di 'A' e 'B' è determinata dalla variabile percentuale_A, che è impostata a 0.7. Ciò significa che, in media, il 70% degli elementi nella colonna sarà 'A', e il restante 30% sarà 'B'.

La funzione np.random.choice è usata per generare la colonna con la distribuzione desiderata. Il parametro p specifica le probabilità per ciascuna scelta (in questo caso, 'A' e 'B').

Infine, il DataFrame risultante viene visualizzato.

1.2.5 Suddivisione di un DataFrame in tre subset di dimensioni simili

[5]:
```
# Creare tre subset di dimensioni simili
subset1 = df.sample(frac=1/3)
df = df.drop(subset1.index)

subset2 = df.sample(frac=1/2)
df = df.drop(subset2.index)

subset3 = df  # L'ultimo subset con il rimanente
```

Questo codice divide il DataFrame originale df in tre subset di dimensioni simili. Ecco come funziona:

subset1 viene creato selezionando casualmente un terzo (frac=1/3) delle righe del DataFrame originale df utilizzando il metodo sample.

Le righe che sono state selezionate per subset1 vengono quindi rimosse da df utilizzando il metodo drop.

Il processo viene ripetuto per creare subset2, ma questa volta viene selezionata la metà (frac=1/2) delle righe rimanenti in df.

Infine, subset3 è semplicemente il DataFrame rimanente dopo che le righe per subset1 e subset2 sono state rimosse.

1.2.6 Calcolo delle percentuali di 'A' e 'B' in un subset di DataFrame

[6]:
```
percentuali_subset1 = subset1['ColonnaAB'].value_counts(normalize=True)
percentuali_subset1
```

[6]:
```
A    0.705706
B    0.294294
Name: ColonnaAB, dtype: float64
```

Questo codice calcola la percentuale di 'A' e 'B' nel subset1. Il metodo value_counts(normalize=True) conta il numero di occorrenze di ciascun valore nella colonna 'ColonnaAB' di subset1 e restituisce le proporzioni rispetto al totale. Quindi, percentuali_subset1 sarà una serie pandas con le percentuali di 'A' e 'B' in subset1.

1.2.7 Generazione e Analisi di un DataFrame con Distribuzione Specifica di Categorie

[7]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split

# Impostare il seed per la riproducibilità
np.random.seed(42)
# Numero totale di elementi nel DataFrame
num_elementi = 1000
```

```
# Percentuale di "A"
percentuale_A = 0.7
# Generare la colonna con distribuzione desiderata
colonna = np.random.choice(['A', 'B'], size=num_elementi, p=[percentuale_A, 1 -␣
 ↪percentuale_A])

# Creare il DataFrame
df = pd.DataFrame({'ColonnaAB': colonna})

# Calcolare la frequenza delle diverse categorie
frequenze = df['ColonnaAB'].value_counts(normalize=True)

print(f"Frequenze relative delle categorie:\n{frequenze}")
```

```
Frequenze relative delle categorie:
A    0.712
B    0.288
Name: ColonnaAB, dtype: float64
```

Questo codice esegue le seguenti operazioni:

Imposta il seed per la riproducibilità: Questo garantisce che i risultati siano riproducibili ogni volta che il codice viene eseguito.

Genera una colonna di dati: Crea una colonna di 1000 elementi, ognuno dei quali è 'A' o 'B'. La probabilità che un elemento sia 'A' è del 70% (come specificato dalla variabile percentuale_A), e la probabilità che un elemento sia 'B' è del 30% (che è 1 - percentuale_A).

Crea un DataFrame: Crea un DataFrame di pandas con la colonna generata.

Calcola la frequenza delle categorie: Calcola la frequenza relativa di 'A' e 'B' nel DataFrame, cioè la percentuale di 'A' e 'B' nel DataFrame.

Stampa le frequenze relative: Infine, stampa le frequenze relative delle categorie 'A' e 'B'.

In sintesi, questo codice è un esempio di come si potrebbe generare un DataFrame con una distribuzione specifica di categorie e calcolare le loro frequenze relative. Questo può essere utile in molte applicazioni, come la simulazione di dati o il test di metodi statistici.

1.2.8 Analisi Statistica e Visualizzazione di Subset di un DataFrame: Un Esempio con Grafici a Torta

[8]:
```
# Calcolare le percentuali di "A" e "B" per ogni subset
percentuali_subset1 = subset1['ColonnaAB'].value_counts(normalize=True)
percentuali_subset2 = subset2['ColonnaAB'].value_counts(normalize=True)
percentuali_subset3 = subset3['ColonnaAB'].value_counts(normalize=True)

# Creare i grafici a torta
```

```
fig, axs = plt.subplots(3, 1, figsize=(6, 12))

# Subset 1
axs[0].pie(percentuali_subset1, labels=percentuali_subset1.index, autopct='%1.
 ↪1f%%', startangle=90)
axs[0].set_title('Subset 1')

# Subset 2
axs[1].pie(percentuali_subset2, labels=percentuali_subset2.index, autopct='%1.
 ↪1f%%', startangle=90)
axs[1].set_title('Subset 2')

# Subset 3
axs[2].pie(percentuali_subset3, labels=percentuali_subset3.index, autopct='%1.
 ↪1f%%', startangle=90)
axs[2].set_title('Subset 3')

# Mostrare il grafico
plt.show()
```

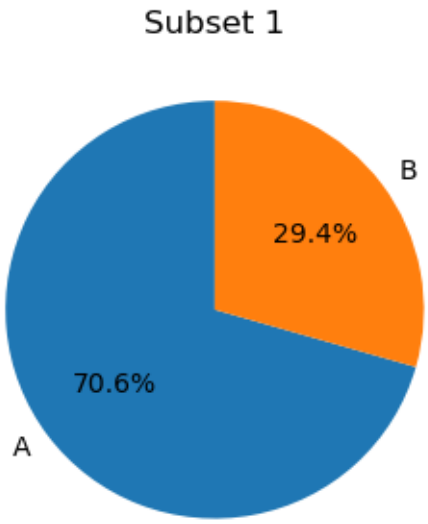
Subset 1
B
29.4%
70.6%
A

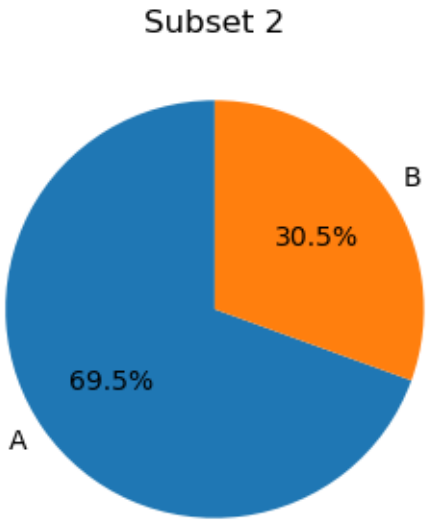
Subset 2
B
30.5%
69.5%
A

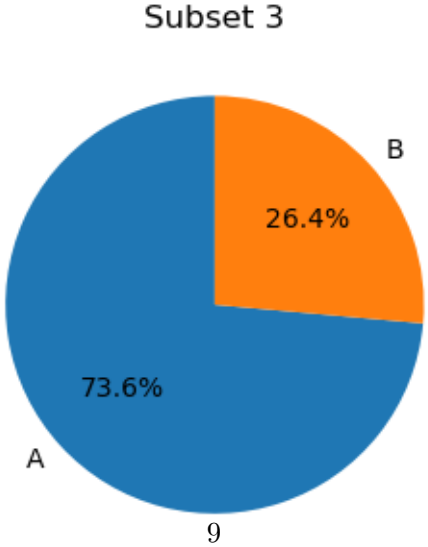
Subset 3
B
26.4%
73.6%
A

Questo codice esegue le seguenti operazioni:

Divide il DataFrame in tre subset: Il DataFrame viene suddiviso in tre subset. Il primo subset è un campione casuale del 33% del DataFrame originale. Il secondo subset è un campione casuale del 50% dei dati rimanenti. Il terzo subset contiene tutti i dati rimanenti.

Calcola le percentuali di 'A' e 'B' per ogni subset: Per ogni subset, calcola la percentuale di 'A' e 'B'.

Crea i grafici a torta: Per ogni subset, crea un grafico a torta che mostra la percentuale di 'A' e 'B'.

Mostra il grafico: Infine, mostra i grafici a torta.

In sintesi, questo codice è un esempio di come si potrebbe eseguire un'analisi statistica su diversi subset di un DataFrame e visualizzare i risultati con dei grafici a torta. Questo può essere utile per confrontare la distribuzione di categorie in diversi subset di un dataset.

1.2.9 Analisi Statistica e Visualizzazione di Training Set e Test Set: Un Esempio con Grafici a Torta

[9]:
```
# Dividere ciascun subset in training set e test set
train_subset1, test_subset1 = train_test_split(subset1, test_size=0.2,␣
 ↪random_state=42)
train_subset2, test_subset2 = train_test_split(subset2, test_size=0.2,␣
 ↪random_state=42)
train_subset3, test_subset3 = train_test_split(subset3, test_size=0.2,␣
 ↪random_state=42)

# Creare il grafico con 6 torte
fig, axs = plt.subplots(3, 2, figsize=(10, 12))

# Funzione per disegnare una torta con etichette
def draw_pie(ax, data, title):
    ax.pie(data, labels=data.index, autopct='%1.1f%%', startangle=90)
    ax.set_title(title)

# Prima riga di torte (Subset 1)
draw_pie(axs[0, 0], train_subset1['ColonnaAB'].value_counts(normalize=True),␣
 ↪'Train Subset 1')
draw_pie(axs[0, 1], test_subset1['ColonnaAB'].value_counts(normalize=True),␣
 ↪'Test Subset 1')

# Seconda riga di torte (Subset 2)
```

```
draw_pie(axs[1, 0], train_subset2['ColonnaAB'].value_counts(normalize=True),␣
 ↪'Train Subset 2')
draw_pie(axs[1, 1], test_subset2['ColonnaAB'].value_counts(normalize=True),␣
 ↪'Test Subset 2')

# Terza riga di torte (Subset 3)
draw_pie(axs[2, 0], train_subset3['ColonnaAB'].value_counts(normalize=True),␣
 ↪'Train Subset 3')
draw_pie(axs[2, 1], test_subset3['ColonnaAB'].value_counts(normalize=True),␣
 ↪'Test Subset 3')

# Regolare lo spaziamento tra i subplots
plt.tight_layout()

# Mostrare il grafico
plt.show()
```

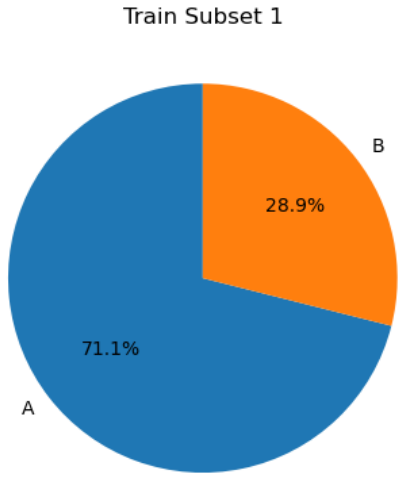
Train Subset 1
B
28.9%
71.1%
A

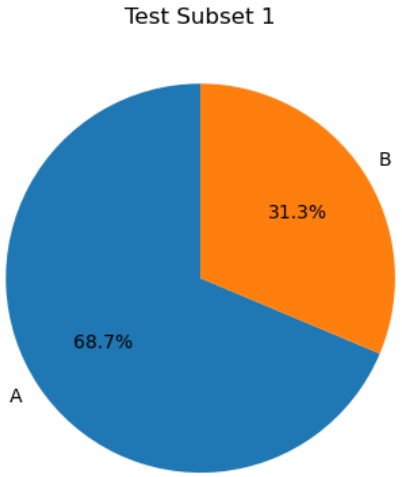
Test Subset 1
B
31.3%
68.7%
A

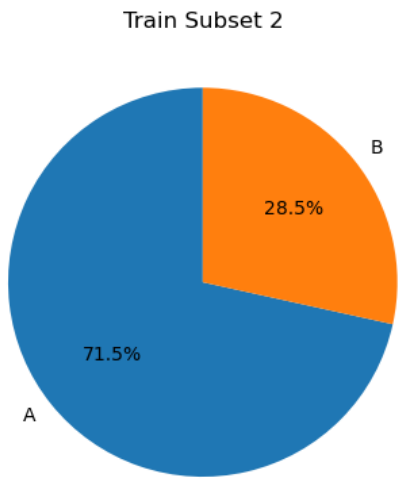
Train Subset 2
B
28.5%
71.5%
A

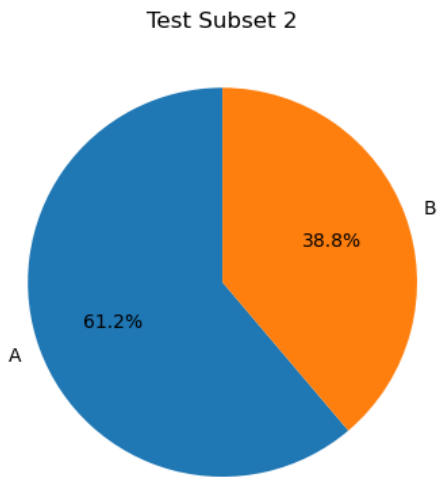
Test Subset 2
B
38.8%
61.2%
A

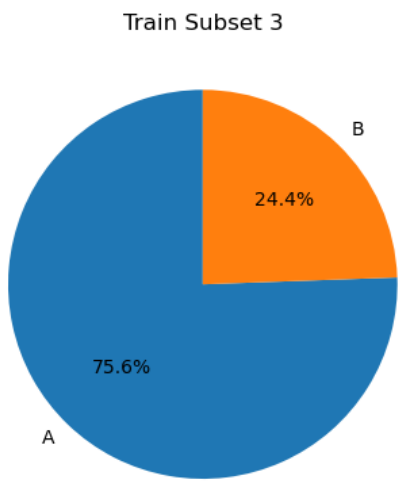
Train Subset 3
B
24.4%
75.6%
A

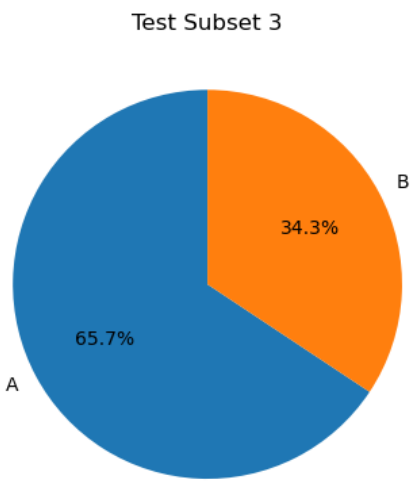
Test Subset 3
B
34.3%
65.7%
A

Questo codice esegue le seguenti operazioni:

Divide ciascun subset in training set e test set: Ogni subset viene suddiviso in un training set (80% dei dati) e un test set (20% dei dati). Questo è fatto per avere un set di dati separato (test set) per valutare le prestazioni del modello che sarà addestrato sul training set.

Crea un grafico con 6 torte: Per ogni training set e test set, crea un grafico a torta che mostra la percentuale di 'A' e 'B'.

Mostra il grafico: Infine, mostra i grafici a torta.

In sintesi, questo codice è un esempio di come si potrebbe eseguire un'analisi statistica su diversi training set e test set estratti da diversi subset di un DataFrame e visualizzare i risultati con dei grafici a torta. Questo può essere utile per confrontare la distribuzione di categorie in diversi training set e test set di un dataset.

1.3 OUTLIERS

1.3.1 Identificazione degli Outliers in un DataFrame: Un Esempio con la Regola delle 3 Sigma

[11]:
```
import pandas as pd
import matplotlib.pyplot as plt

# Crea un DataFrame di esempio
data = {'Valori': [1, 2, 3, 4, 5, 10, 15, 20, 25, 300, 1000, 100000000,␣
 ↪-50000000, -50]}
df = pd.DataFrame(data)
# Lista con outliers da entrambi i lati

# Calcola la media e la deviazione standard
mean_value = df['Valori'].mean()
std_dev = df['Valori'].std()

# Identifica gli outliers considerando ±3 sigma dalla media
outliers = df[(df['Valori'] > mean_value + 3 * std_dev) | (df['Valori'] <␣
 ↪mean_value - 3 * std_dev)]
outliers
```

[11]:
```
      Valori
11  100000000
```

Questo codice esegue le seguenti operazioni:

Crea un DataFrame di esempio: Crea un DataFrame di pandas con una colonna chiamata 'Valori' che contiene una lista di numeri, alcuni dei quali sono molto più grandi o più piccoli degli altri (outliers).

Calcola la media e la deviazione standard: Calcola la media e la deviazione standard dei valori nel DataFrame.

Identifica gli outliers: Identifica gli outliers come quei valori che sono a più di 3 deviazioni standard (sigma) dalla media. Questo è un metodo comune per identificare gli outliers in un set di dati.

In sintesi, questo codice è un esempio di come si potrebbe identificare gli outliers in un set di dati utilizzando la regola delle 3 sigma. Gli outliers identificati vengono poi salvati in un nuovo DataFrame chiamato 'outliers'.

1.3.2 Calcolo della media e della deviazione standard in un DataFrame

[12]:
```
# Calcola la media e la deviazione standard
mean_value = df['Valori'].mean()
std_dev = df['Valori'].std()
std_dev
```

[12]:
```
30786384.39895254
```

Questo codice calcola la media e la deviazione standard della colonna 'Valori' nel DataFrame df.

Il metodo mean() calcola la media (il valore medio) dei dati nella colonna 'Valori'. Il risultato viene assegnato alla variabile mean_value.

Il metodo std() calcola la deviazione standard, che è una misura della quantità di variazione o dispersione dei dati. Il risultato viene assegnato alla variabile std_dev.

Infine, il valore di std_dev viene visualizzato.

1.3.3 Visualizzazione di Outliers in un Grafico a Dispersione: Un Esempio con Media e Deviazione Standard

[13]:
```
# Crea un grafico a dispersione
plt.scatter(df.index, df['Valori'], label='Valori')

# Evidenzia gli outliers nel grafico con un colore diverso
plt.scatter(outliers.index, outliers['Valori'], color='red', label='Outliers')

# Aggiungi la media e la deviazione standard al grafico
plt.axhline(y=mean_value, color='green', linestyle='--', label='Media')
plt.axhline(y=mean_value + 3 * std_dev, color='orange', linestyle='--',␣
 ↪label='±3 Deviazioni Standard')
plt.axhline(y=mean_value - 3 * std_dev, color='orange', linestyle='--')

# Aggiungi etichette e legenda al grafico
plt.xlabel('Indice')
plt.ylabel('Valori')
plt.title('Grafico con Outliers Evidenziati')
plt.legend()

# Mostra il grafico
plt.show()
```

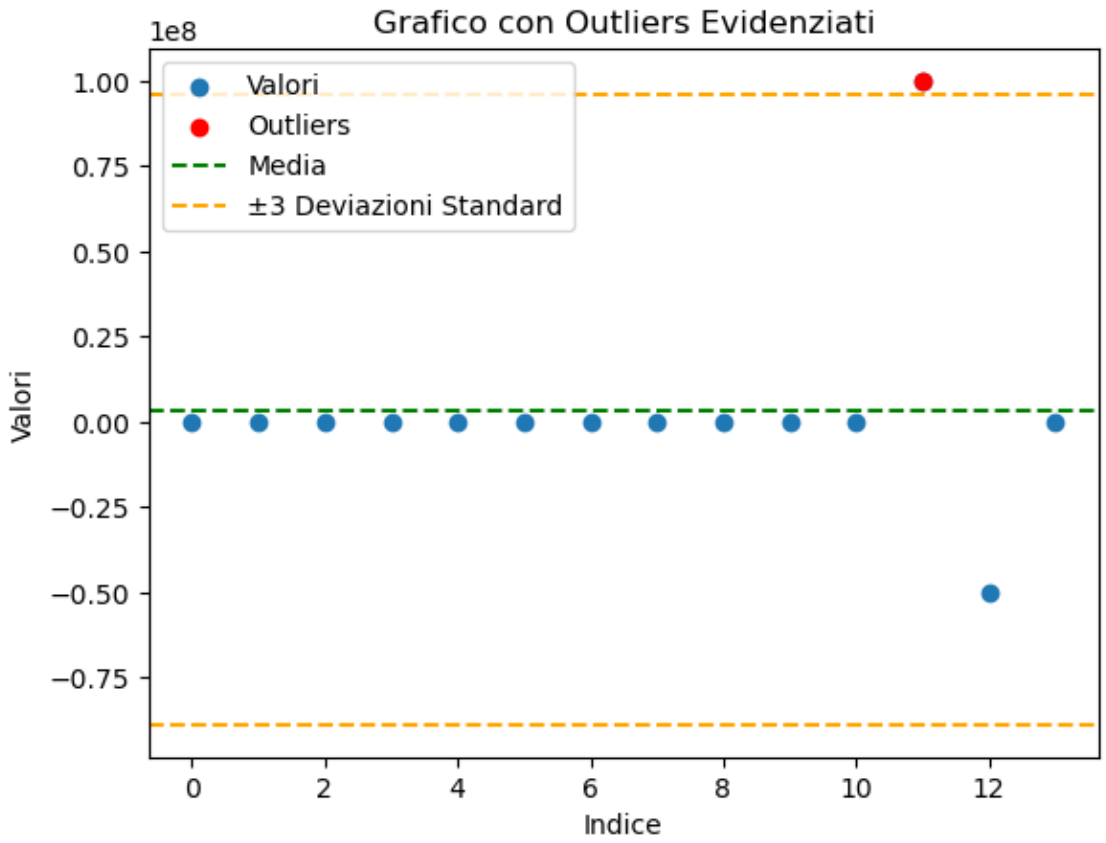

Questo codice esegue le seguenti operazioni:

Crea un grafico a dispersione: Crea un grafico a dispersione con l'indice del DataFrame sull'asse x e i valori sull'asse y.

Evidenzia gli outliers nel grafico: Gli outliers vengono evidenziati nel grafico a dispersione con un colore diverso.

Aggiunge la media e la deviazione standard al grafico: Aggiunge linee orizzontali al grafico per indicare la media e la deviazione standard (±3 sigma).

Aggiunge etichette e legenda al grafico: Aggiunge etichette agli assi, un titolo al grafico e una legenda che indica cosa rappresentano i diversi colori e linee.

Mostra il grafico: Infine, mostra il grafico.

In sintesi, questo codice è un esempio di come si potrebbe visualizzare un set di dati e gli outliers associati in un grafico a dispersione, con linee aggiunte per indicare la media e la deviazione standard.

1.3.4 Identificazione degli Outliers in un DataFrame Multidimensionale: Un Esempio con la Regola delle k Sigma

[14]:
```
import pandas as pd
import matplotlib.pyplot as plt

# Crea un DataFrame di esempio con 4 features
data = {'Feature1': [1, 2000, 3, 4, 50000, 10, 15, 20, 2500000, 300000000,␣
 ↪100000000],
        'Feature2': [2, 4, 6, 8, 10, 20, 30, 40, 50000, 60, 200],
        'Feature3': [5, 10, 15, 20000, 25, 50, 75, 100, 125, 150, 500000],
        'Feature4': [1, -20000000, 3, 4000000000, 5, 10, 15, 20, 20005, 30,␣
 ↪10000]}

df = pd.DataFrame(data)

# Definisci il numero minimo di features che devono superare la soglia per␣
 ↪considerare un dato un outlier
min_features_threshold = 1
k=2 #intervallo di confidenza

# Lista per salvare gli indici degli outliers
outlier_indices = []

# Itera su ogni feature
for feature in df.columns:
    mean_value = df[feature].mean()
    std_dev = df[feature].std()

    # Identifica gli outliers per ciascuna feature
    df['Outlier_' + feature] = (df[feature] > mean_value + k * std_dev) |␣
 ↪(df[feature] < mean_value - k * std_dev)
    print(df)
```

```
     Feature1  Feature2  Feature3    Feature4  Outlier_Feature1
0           1         2         5           1             False
1        2000         4        10   -20000000             False
2           3         6        15           3             False
3           4         8     20000  4000000000             False
4       50000        10        25           5             False
5          10        20        50          10             False
6          15        30        75          15             False
7          20        40       100          20             False
8     2500000     50000       125       20005             False
9   300000000        60       150          30              True
10  100000000       200    500000       10000             False
     Feature1  Feature2  Feature3    Feature4  Outlier_Feature1  \
0           1         2         5           1             False
```

```
1        2000         4        10   -20000000             False
2           3         6        15           3             False
3           4         8     20000  4000000000             False
4       50000        10        25           5             False
5          10        20        50          10             False
6          15        30        75          15             False
7          20        40       100          20             False
8     2500000     50000       125       20005             False
9   300000000        60       150          30              True
10  100000000       200    500000       10000             False

    Outlier_Feature2
0              False
1              False
2              False
3              False
4              False
5              False
6              False
7              False
8               True
9              False
10             False
     Feature1  Feature2  Feature3    Feature4  Outlier_Feature1  \
0           1         2         5           1             False
1        2000         4        10   -20000000             False
2           3         6        15           3             False
3           4         8     20000  4000000000             False
4       50000        10        25           5             False
5          10        20        50          10             False
6          15        30        75          15             False
7          20        40       100          20             False
8     2500000     50000       125       20005             False
9   300000000        60       150          30              True
10  100000000       200    500000       10000             False

    Outlier_Feature2  Outlier_Feature3
0              False             False
1              False             False
2              False             False
3              False             False
4              False             False
5              False             False
6              False             False
7              False             False
8               True             False
9              False             False
10             False              True
```

```
     Feature1  Feature2  Feature3    Feature4  Outlier_Feature1  \
0           1         2         5           1             False
1        2000         4        10   -20000000             False
2           3         6        15           3             False
3           4         8     20000  4000000000             False
4       50000        10        25           5             False
5          10        20        50          10             False
6          15        30        75          15             False
7          20        40       100          20             False
8     2500000     50000       125       20005             False
9   300000000        60       150          30              True
10  100000000       200    500000       10000             False

    Outlier_Feature2  Outlier_Feature3  Outlier_Feature4
0              False             False             False
1              False             False             False
2              False             False             False
3              False             False              True
4              False             False             False
5              False             False             False
6              False             False             False
7              False             False             False
8               True             False             False
9              False             False             False
10             False              True             False
```

Questo codice esegue le seguenti operazioni:

Crea un DataFrame di esempio: Crea un DataFrame di pandas con quattro colonne (o "features") che contengono una lista di numeri, alcuni dei quali sono molto più grandi o più piccoli degli altri (outliers).

Definisce il numero minimo di features che devono superare la soglia per considerare un dato un outlier: Questo è un parametro che può essere modificato in base alle esigenze specifiche dell'analisi.

Crea una lista per salvare gli indici degli outliers: Questa lista sarà popolata con gli indici dei dati che sono considerati outliers.

Itera su ogni feature: Per ogni feature nel DataFrame, calcola la media e la deviazione standard, e identifica gli outliers. Un outlier è definito come un valore che è a più di k deviazioni standard (sigma) dalla media. Questo è un metodo comune per identificare gli outliers in un set di dati.

Identifica gli outliers per ciascuna feature: Aggiunge una nuova colonna al DataFrame per ogni feature, indicando se ogni valore è un outlier per quella feature.

Stampa il DataFrame: Infine, stampa il DataFrame dopo ogni iterazione. Questo ti permette di vedere come il DataFrame cambia dopo ogni iterazione.

> In sintesi, questo codice è un esempio di come si potrebbe identificare gli outliers in un DataFrame utilizzando la regola delle k sigma. Gli outliers vengono identificati per ogni feature e vengono aggiunte nuove colonne al DataFrame per indicare gli outliers.

1.3.5 Calcolo del numero di valori outlier in un DataFrame

[15]:
```
df['Num_Outliers'] = df.filter(like='Outlier_').sum(axis=1)
df
```

[15]:

	Feature1	Feature2	Feature3	Feature4	Outlier_Feature1	\
0	1	2	5	1	False	
1	2000	4	10	-20000000	False	
2	3	6	15	3	False	
3	4	8	20000	4000000000	False	
4	50000	10	25	5	False	
5	10	20	50	10	False	
6	15	30	75	15	False	
7	20	40	100	20	False	
8	2500000	50000	125	20005	False	
9	300000000	60	150	30	True	
10	100000000	200	500000	10000	False	

	Outlier_Feature2	Outlier_Feature3	Outlier_Feature4	Num_Outliers
0	False	False	False	0
1	False	False	False	0
2	False	False	False	0
3	False	False	True	1
4	False	False	False	0
5	False	False	False	0
6	False	False	False	0
7	False	False	False	0
8	True	False	False	1
9	False	False	False	1
10	False	True	False	1

Questo codice aggiunge una nuova colonna al DataFrame df chiamata 'Num_Outliers'. Questa colonna è calcolata sommando il numero di valori 'Outlier_' in ciascuna riga del DataFrame.

Il metodo filter(like='Outlier_') seleziona tutte le colonne che contengono la stringa 'Outlier_' nel loro nome. Il metodo sum(axis=1) somma i valori in ciascuna riga per queste colonne.

Infine, il DataFrame aggiornato df viene visualizzato.

1.3.6 Identificazione e Filtraggio degli Outliers in un DataFrame Multidimensionale: Un Esempio con la Regola delle k Sigma

[16]:
```
# Calcola il numero di features che superano la soglia per ogni riga
df['Num_Outliers'] = df.filter(like='Outlier_').sum(axis=1)

# Filtra i dati per mantenere solo le righe con almeno il numero minimo di␣
 ↪features superanti la soglia
```

```
outliers = df[df['Num_Outliers'] >= min_features_threshold]

# Aggiungi una colonna che indica se il record è un outlier o meno
df['Is_Outlier'] = df.index.isin(outliers.index)

# Rimuovi colonne ausiliarie
df.drop(df.filter(like='Outlier_').columns, axis=1, inplace=True)
df.drop('Num_Outliers', axis=1, inplace=True)
df
```

[16]:

	Feature1	Feature2	Feature3	Feature4	Is_Outlier
0	1	2	5	1	False
1	2000	4	10	-20000000	False
2	3	6	15	3	False
3	4	8	20000	4000000000	True
4	50000	10	25	5	False
5	10	20	50	10	False
6	15	30	75	15	False
7	20	40	100	20	False
8	2500000	50000	125	20005	True
9	300000000	60	150	30	True
10	100000000	200	500000	10000	True

Questo codice esegue le seguenti operazioni:

Calcola il numero di features che superano la soglia per ogni riga: Aggiunge una nuova colonna al DataFrame che conta il numero di features che sono considerate outliers per ogni riga.

Filtra i dati per mantenere solo le righe con almeno il numero minimo di features superanti la soglia: Crea un nuovo DataFrame 'outliers' che contiene solo le righe del DataFrame originale in cui il numero di features che superano la soglia è maggiore o uguale al numero minimo di features impostato.

Aggiunge una colonna che indica se il record è un outlier o meno: Aggiunge una nuova colonna al DataFrame originale che indica se ogni riga è considerata un outlier o meno.

Rimuove le colonne ausiliarie: Rimuove le colonne ausiliarie che sono state aggiunte durante il processo di identificazione degli outliers.

Stampa il DataFrame: Infine, stampa il DataFrame.

In sintesi, questo codice è un esempio di come si potrebbe identificare gli outliers in un DataFrame multidimensionale utilizzando la regola delle k sigma e mantenendo solo le righe che hanno un numero sufficiente di features che superano la soglia.

1.3.7 Calcolo del numero di caratteristiche in un DataFrame

[17]:
```
# Organizza i grafici in una matrice, con una colonna e 4 righe
num_features = len(df.columns) - 1  # Escludi la colonna 'Is_Outlier'
num_features
```

[17]: 4

Questo codice calcola il numero di caratteristiche (o colonne) nel DataFrame df, escludendo la colonna 'Is_Outlier'.

Il metodo len(df.columns) restituisce il numero totale di colonne in df. Sottraendo 1, si esclude la colonna 'Is_Outlier'. Il risultato viene assegnato alla variabile num_features.

Quindi, num_features rappresenta il numero di colonne nel DataFrame df che non sono 'Is_Outlier'.

1.3.8 Visualizzazione di Outliers in un DataFrame Multidimensionale: Un Esempio con Grafici a Dispersione

[18]:
```
# Organizza i grafici in una matrice, con una colonna e 4 righe
num_features = len(df.columns) - 1  # Escludi la colonna 'Is_Outlier'
num_rows = num_features
num_cols = 1  # Una colonna

plt.figure(figsize=(6, 4 * num_rows))
for i, feature in enumerate(df.columns[:-1]):  # Escludi la colonna 'Is_Outlier'
    plt.subplot(num_rows, num_cols, i + 1)
    plt.scatter(df.index, df[feature], c=df['Is_Outlier'], cmap='coolwarm',␣
 ↪alpha=0.8)
    plt.title(f'Outliers in Rosso - {feature}')
    plt.xlabel('Indice')
    plt.ylabel('Feature')

plt.tight_layout()
plt.show()
```

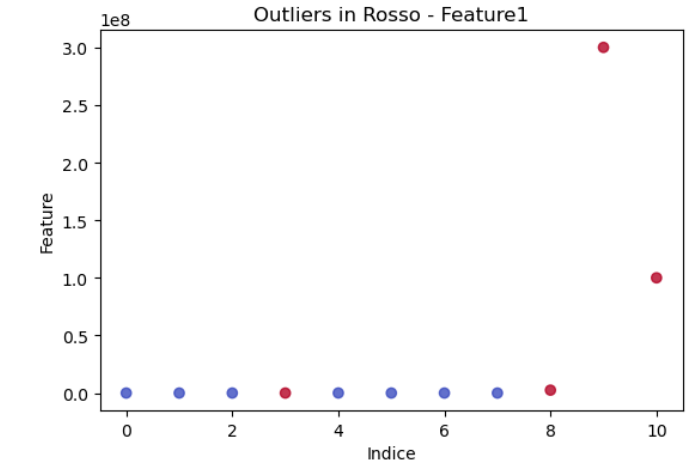
Outliers in Rosso - Feature1
1e8
3.0
2.5
2.0
1.5
1.0
0.5
0.0
Feature
0
2
4
6
8
10
Indice

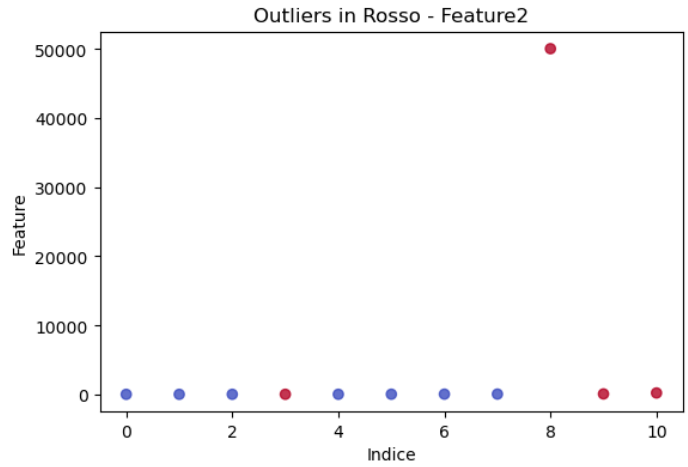
Outliers in Rosso - Feature2
50000
40000
30000
20000
10000
0
Feature
0
2
4
6
8
10
Indice

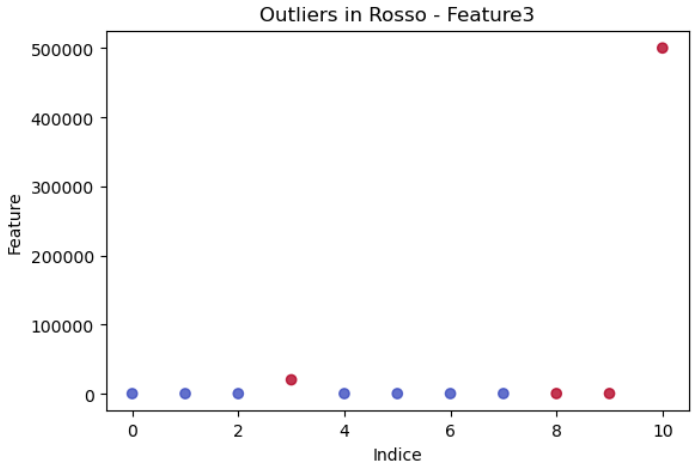
Outliers in Rosso - Feature3
500000
400000
300000
200000
100000
0
Feature
0
2
4
6
8
10
Indice

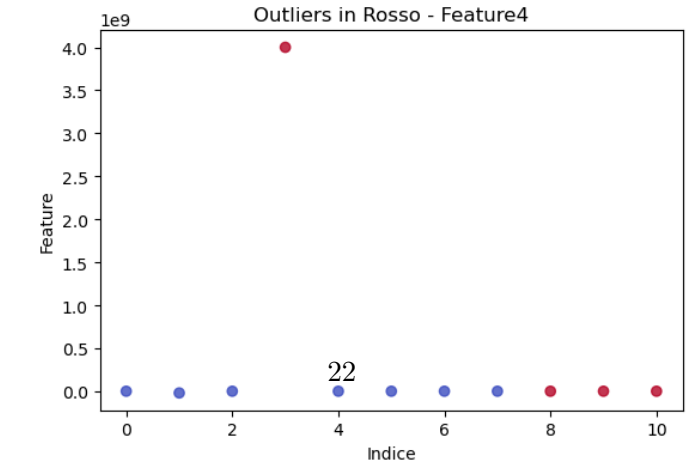
Outliers in Rosso - Feature4
1e9
4.0
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
Feature
0
2
4
6
8
10
Indice

Questo codice esegue le seguenti operazioni:

Organizza i grafici in una matrice: Crea una griglia di grafici con una colonna e un numero di righe pari al numero di features nel DataFrame (escludendo la colonna 'Is_Outlier').

Crea un grafico a dispersione per ogni feature: Per ogni feature nel DataFrame, crea un grafico a dispersione con l'indice del DataFrame sull'asse x e i valori della feature sull'asse y. Gli outliers sono colorati in rosso, mentre i dati normali sono colorati in blu.

Mostra il grafico: Infine, mostra i grafici a dispersione.

> In sintesi, questo codice è un esempio di come si potrebbe visualizzare un DataFrame multidimensionale e gli outliers associati in una serie di grafici a dispersione. Questo può essere utile per esaminare visivamente la distribuzione dei dati e la posizione degli outliers in ciascuna feature.

1.3.9 Visualizzazione di Outliers in un DataFrame Multidimensionale: Un Esempio con Grafici a Dispersione

[19]:
```
# Elimina le righe corrispondenti agli outliers quelli che hanno almeno una␣
↪features fuoriscala
df_filtered = df[df['Is_Outlier'] == False]
df_filtered
```

[19]:

	Feature1	Feature2	Feature3	Feature4	Is_Outlier
0	1	2	5	1	False
1	2000	4	10	-20000000	False
2	3	6	15	3	False
4	50000	10	25	5	False
5	10	20	50	10	False
6	15	30	75	15	False
7	20	40	100	20	False

Questo codice esegue le seguenti operazioni:

Organizza i grafici in una matrice: Crea una griglia di grafici con una colonna e un numero di righe pari al numero di features nel DataFrame (escludendo la colonna 'Is_Outlier').

Crea un grafico a dispersione per ogni feature: Per ogni feature nel DataFrame, crea un grafico a dispersione con l'indice del DataFrame sull'asse x e i valori della feature sull'asse y. Gli outliers sono colorati in rosso, mentre i dati normali sono colorati in blu.

Mostra il grafico: Infine, mostra i grafici a dispersione.

> In sintesi, questo codice è un esempio di come si potrebbe visualizzare un DataFrame multidimensionale e gli outliers associati in una serie di grafici a dispersione. Questo può essere utile per esaminare visivamente la distribuzione dei dati e la posizione degli outliers in ciascuna feature. Questo codice esegue le seguenti operazioni:

Filtra il DataFrame per rimuovere gli outliers: Crea un nuovo DataFrame 'df_filtered' che contiene solo le righe del DataFrame originale in cui la colonna 'Is_Outlier' è False. In altre parole, rimuove tutte le righe che sono state identificate come outliers.

In sintesi, questo codice è un esempio di come si potrebbe filtrare un DataFrame per rimuovere gli outliers. Dopo l'esecuzione di questo codice, 'df_filtered' conterrà solo i dati che non sono stati identificati come outliers.